

Depresión en Estudiantes Universitarios: Un Enfoque con Machine Learning

Identificando los Factores de Riesgo Clave para
Intervenciones Tempranas

Alumna: Florencia Mauvesin Tögel

Comisión: 67395

Profesor: Gustavo Benitez

Tutor: Carlos Davoli.

Entrega Final.

Data Science II

Abstract y Objetivo del Proyecto

Abstract

Este proyecto utiliza **datos de estudiantes** para desarrollar un **modelo de Machine Learning** capaz de **predecir la depresión**. Identificamos los **factores de riesgo más significativos** para guiar futuras estrategias de apoyo al bienestar estudiantil.

Objetivo Principal

Desarrollar un **modelo predictivo robusto** para identificar proactivamente a los estudiantes en riesgo y **entender los factores que más influyen** en su salud mental.

El Problema: ¿Por qué es Importante?

Contexto

La depresión es un **problema creciente** y preocupante en la población estudiantil, afectando directamente su **rendimiento académico** y su **bienestar general**.

Preguntas Clave

¿Podemos predecir qué estudiantes están en mayor riesgo de sufrir depresión?
¿Qué factores, como el estrés académico, el estrés financiero o los hábitos de vida, son los más influyentes?

La Necesidad

Existe una clara necesidad de **herramientas basadas en datos** para que las instituciones universitarias puedan **ofrecer apoyo** de manera proactiva.

Metodología y Datos

Fuente de Datos:

Utilice un dataset de kaggle con información demográfica, académica y de hábitos de aproximadamente 28,000 estudiantes.

Metodología en 5 Pasos Clave:

1-Limpieza y preprocesamiento de datos: Manejo de valores nulos y eliminación de datos irrelevantes (ej. Profession). Corrección de inconsistencias y estandarización de categorías (ej. en City, Degree). Análisis y tratamiento de valores atípicos (outliers) en la variable Age.

2-Análisis exploratorio de datos (EDA): Visualización de la distribución de variables clave. Validación gráfica de las hipótesis iniciales (relación entre estrés, sueño, etc., y la depresión). Análisis de correlación para entender las relaciones lineales entre variables numéricas.

Metodología y Datos

3-Ingeniería y preparación de características: Codificación de variables categóricas a formato numérico (Label Encoding para binarias y One-Hot Encoding para nominales). Escalado de características numéricas (StandardScaler) para asegurar que todas contribuyan equitativamente al modelo.



4-Modelado predictivo y evaluación: División de datos en conjuntos de entrenamiento y prueba. Entrenamiento de dos modelos robustos: Random Forest y XGBoost. Optimización de hiperparámetros del Random Forest usando GridSearchCV para mitigar el sobreajuste. Evaluación de los modelos con métricas clave (Accuracy, Precision, Recall, F1-Score, ROC AUC).

5-Análisis de resultados: Comparación del rendimiento de ambos modelos para seleccionar el mejor. Análisis de la importancia de las variables para identificar los predictores más influyentes.

Hallazgos Clave: ¿Que nos dicen nuestros datos?

1. ¿influye el estrés financiero y académico?:


Hallazgo: Sí, de manera contundente. A medida que aumentan los niveles de estrés financiero y presión académica, la proporción de estudiantes con depresión crece significativamente.



Hallazgos Clave: ¿Que nos dicen nuestros datos?

2. ¿hay relación entre las horas de sueño y la depresión?:


Hallazgo: Sí, Se observa una mayor proporción de estudiantes con depresión entre quienes duermen menos de 5 horas por noche. A medida que aumenta la duración del sueño, la cantidad de estudiantes con depresión tiende a disminuir.



Hallazgos Clave: ¿Que nos dicen nuestros datos?

3. ¿importa la satisfacción con los estudios?:


Hallazgo: Sí, y mucho. Una menor satisfacción académica está fuertemente asociada con una mayor probabilidad de tener depresión.



Hallazgos Clave: ¿Que nos dicen nuestros datos?

4. ¿y los antecedentes familiares de enfermedad mental?:


Hallazgo: Menos de lo esperado. Aunque existe una ligera diferencia, en nuestros datos no parece ser un factor tan determinante como los estresores directos



Hallazgos Clave: ¿Que nos dicen nuestros datos?


5. ¿existen diferencias de género?:

Hallazgo: Sí, se observan diferencias. En la muestra analizada, la prevalencia de depresión es notablemente mayor en el género masculino. Aunque la diferencia es bastante ligera.



Análisis de Correlación


Después de explorar las relaciones entre variables específicas y la depresión a través de gráficos de conteo para nuestras hipótesis, es importante examinar las correlaciones numéricas generales en nuestro dataset. Comence evaluando las correlaciones de **Pearson**



Hallazgo: se puede ver que la mayoría de los **coeficientes de correlación entre las variables** numéricas y con la variable objetivo "Depression" **son relativamente bajos**, cercanos a cero. Lo que sugiere que no existen relaciones lineales fuertes en nuestros datos. Este hallazgo inicial me resultó un tanto sorprendente, dado que en los barplots de hipótesis previas habíamos observado claras tendencias y proporciones que indicaban una relación entre variables.

Análisis de Correlación

Ante las bajas correlaciones lineales mostradas por Pearson, y considerando la naturaleza de algunas de las variables que son ordinales aunque tratadas numéricamente (escalas de 1 a 5, o rangos de horas), voy a calcular como proximo paso, la correlación de **Spearman**.



Hallazgo: El heatmap de Correlación de Spearman también nos confirmó que las correlaciones entre las variables predictoras numéricas y la Depression son, en su mayoría, bajas.

Implicaciones para el Modelado

La confirmación de bajas correlaciones lineales/monotónicas directas es un hallazgo clave. Indica que la relación entre los factores de riesgo y la depresión en estudiantes es probablemente multifactorial y no lineal, o que involucra interacciones complejas entre las variables. Esto refuerza la necesidad de utilizar un modelo de Machine Learning que sea capaz de aprender patrones más sofisticados, como modelos basados por ejemplo, en árboles (Random Forest, XGBoost) ya que estos algoritmos no dependen de la linealidad y pueden capturar la complejidad que los coeficientes de correlación no revelan.

Encontrando el Modelo Correcto: Proceso con Random Forest.

Paso 1: Entrenamiento del modelo inicial:

El primer modelo fue un Random Forest. Obtuvo un buen 83.5% de Accuracy en los datos de prueba, pero...

Paso 2: Detección de sobreajuste (overfitting):

...apareció una señal de alerta: el modelo tenía un rendimiento perfecto (100%) en los datos con los que fue entrenado.

¿Qué significa esto? El modelo estaba "memorizando" los datos de entrenamiento en lugar de "aprender" a generalizar. Esto lo haría poco fiable con datos nuevos. (Accuracy Test (83.5%) vs. Accuracy Train (100%)).

Paso 3: La solución - optimización de hiperparámetros:

Para corregir esto, realice una búsqueda (GridSearchCV) para encontrar los parámetros óptimos que equilibraran el rendimiento y la generalización.

Paso 4: El resultado - un modelo random forest robusto:

El resultado fue un modelo optimizado con un rendimiento sólido y, lo más importante, con una brecha mucho menor entre los datos de entrenamiento y prueba, eliminando el problema del sobreajuste.


Random Forest vs. Random Forest Optimizado

--- Comparación Test vs. Train ---

Accuracy (Test): 0.8353 | Accuracy (Train): 1.0000

F1-Score (Test): 0.8618 | F1-Score (Train): 1.0000

ROC AUC (Test): 0.9111 | ROC AUC (Train): 1.0000




Comparación Test vs. Train (Modelo Optimizado)


Accuracy: Test 0.8425 | Train 0.8804

F1-Score: Test 0.8638 | Train 0.8965

ROC AUC: Test 0.9170 | Train 0.9555



¿Se puede Mejorar? Probando con XGBoost.



--- Comparación de Rendimiento: Test vs. Train ---

Accuracy: Test 0.8452 | Train 0.8679

F1-Score: Test 0.8699 | Train 0.8890

ROC AUC: Test 0.9187 | Train 0.9401

El modelo **XGBoost** no solo es robusto, sino que supera ligeramente al Random Forest optimizado, convirtiéndose en el **mejor modelo**.

CONCLUSIONES

1. **Análisis del Rendimiento del Modelo XGBoost:** El modelo XGBoost ha demostrado ser una elección sólida y efectiva para predecir la depresión en estudiantes.
2. **Desempeño Robusto:** Con un Recall del 88.35%, el modelo es muy bueno identificando a la mayoría de los estudiantes con depresión, lo cual es vital en salud mental. Su Precision del 85.67% asegura que cuando predice depresión, acierta en la gran mayoría de los casos, haciendo sus predicciones muy fiables.
3. **Mínimo Sobreajuste:** Aunque hay una pequeña brecha entre el rendimiento en entrenamiento y prueba (por ejemplo, F1-Score: Prueba 0.8699 vs. Entrenamiento 0.8890), esta diferencia es mínima. Esto confirma que el modelo tiene una excelente capacidad para generalizar y no está simplemente memorizando los datos de entrenamiento.
4. **Superior al Random Forest Optimizado:** Al compararlo con el Random Forest previamente optimizado, XGBoost se posiciona ligeramente por encima en las métricas clave. Además, es crucial notar que XGBoost, sin necesidad de optimización profunda, muestra mucho menos sobreajuste que el primer modelo de Random Forest. Un modelo más equilibrado desde el principio

GRACIAS!